Guía de Laboratorio: Relación entre Peso y Estatura

Análisis Exploratorio, Regresión y Selección de Variables

Profesor: Mario Morales

Tabla de contenidos

1. Introducción **1**

2. Objetivos **2**

3. Descripción de los Datos **2**

4. Procedimiento y Análisis Requeridos **2**
A. Preparación y Descriptiva por Niveles 2
B. Pruebas de Hipótesis Básicas (Diferencia de Medias) 3
C. Modelamiento Estadístico y Regresión 3
D. Pruebas de Hipótesis sobre los Coeficientes 3
E. Selección de Variables y Modelos 4

5. Código de Apoyo en R (Tips para los Estudiantes) **4**

1. Introducción

En el campo de la antropometría y la salud pública, la relación entre el peso y la estatura de los individuos es fundamental para establecer índices de desarrollo y riesgo. Este laboratorio tiene como propósito utilizar datos reales recolectados en clase para explorar esta relación, aplicando técnicas de estadística descriptiva bivariada, modelos de regresión lineal y métodos de selección de variables para determinar el modelo más adecuado y parsimonioso.

2. Objetivos

- **Exploratorio:** Calcular estadísticas descriptivas y visualizar la distribución del peso y la estatura según el sexo del estudiante.
- **Modelamiento:** Ajustar modelos de regresión lineal (simples y múltiples) para predecir el peso a partir de la estatura, el sexo y la edad.
- **Inferencia:** Ejecutar pruebas de hipótesis para contrastar si el efecto de la estatura sobre el peso difiere significativamente entre hombres y mujeres.
- **Selección de Variables:** Utilizar criterios estadísticos (ANOVA, AIC, BIC) y algoritmos de selección (Forward, Backward, Stepwise y Mejores Subconjuntos) para identificar el modelo óptimo.

3. Descripción de los Datos

Los datos provienen del formato de registro "Laboratorio de estadística Relación entre peso y estatura". Las variables de interés recolectadas para los 30 estudiantes son:

- `Sexo`: Variable categórica (Femenino / Masculino).
- `Edad`: Edad del estudiante en años.
- `Estatura`: Estatura medida en metros.
- `Peso`: Se tomaron tres mediciones independientes de peso en kilogramos (Medición 1, Medición 2, Medición 3) para reducir el error de medición.

Nota metodológica: El formato incluye un espacio para un promedio; el primer paso analítico será calcular el peso promedio exacto a partir de las tres mediciones individuales.

4. Procedimiento y Análisis Requeridos

A. Preparación y Descriptiva por Niveles

1. **Cálculo del Peso Promedio:** A partir de las tres mediciones, calcule una nueva variable llamada `peso_prom`.
2. **Estadísticas de Resumen:** Construya una tabla que muestre la media, desviación estándar, mínimo y máximo para la estatura, la edad y el peso promedio, agrupada por la variable `Sexo`.
3. **Visualización Bivariada:** Genere un diagrama de dispersión (Scatterplot) donde el eje X sea la estatura y el eje Y sea el peso promedio. Utilice colores o formas distintas para diferenciar entre hombres y mujeres.

B. Pruebas de Hipótesis Básicas (Diferencia de Medias)

Antes de ajustar el modelo, verifique si existen diferencias basales entre los grupos:

- **Hipótesis 1:** ¿Difiere la estatura promedio entre hombres y mujeres?

$$H_0 : \mu_{estatura_H} = \mu_{estatura_M}$$

$$H_1 : \mu_{estatura_H} \neq \mu_{estatura_M}$$

- Ejecute una prueba t de Student para muestras independientes (verificando previamente los supuestos de normalidad y homogeneidad de varianzas).

C. Modelamiento Estadístico y Regresión

1. **Regresión Lineal Simple (Modelo Global):** Ajuste el modelo sin distinguir por sexo para evaluar la tendencia general:

$$Peso_i = \beta_0 + \beta_1 Estatura_i + \epsilon_i$$

   - Interprete el valor estimado de β_1 en el contexto del problema.
   - Reporte e interprete el coeficiente de determinación R^2.

2. **Modelo de Regresión Múltiple con Interacción:** Para responder a la pregunta de si la relación entre peso y estatura es la misma para hombres y mujeres, defina una variable indicadora (dummy) D tal que $D = 1$ si es hombre y $D = 0$ si es mujer. Ajuste el siguiente modelo con interacción:

$$Peso_i = \beta_0 + \beta_1 Estatura_i + \beta_2 D_i + \beta_3 (Estatura_i \times D_i) + \epsilon_i$$

D. Pruebas de Hipótesis sobre los Coeficientes

A partir del modelo con interacción, evalúe las siguientes hipótesis:

- **Hipótesis 2 (Efecto Principal del Sexo en el Intercepto):**

$$H_0 : \beta_2 = 0$$

  (¿Tienen hombres y mujeres de la misma estatura un peso esperado diferente?)

- **Hipótesis 3 (Igualdad de Pendientes):**

$$H_0 : \beta_3 = 0$$

  (¿Es el cambio en el peso por cada metro adicional de estatura el mismo para hombres que para mujeres?)

Concluya formalmente sobre el valor p asociado al coeficiente β_3. Si se rechaza H_0, significa que se requieren ecuaciones de regresión separadas para cada sexo.

E. Selección de Variables y Modelos

¿Es necesario incluir la variable `Edad` para predecir el peso de los estudiantes, o basta con la estatura y el sexo? Responda a esta pregunta aplicando los siguientes métodos:

1. **Comparación de Modelos Anidados (ANOVA):** Ajuste un modelo reducido (sin edad) y un modelo completo (con edad) y compárelos mediante un análisis de varianza.

$$H_0 : \beta_{Edad} = 0 \quad \text{(El modelo reducido es suficiente)}$$

$$H_1 : \beta_{Edad} \neq 0 \quad \text{(El modelo completo es significativamente mejor)}$$

2. **Procedimientos de Selección Automática:** A partir de un modelo completo que incluya todas las variables (`Estatura`, `Sexo`, `Edad` y sus posibles interacciones), utilice la función `step()` para ejecutar las siguientes estrategias basadas en el Criterio de Información de Akaike (AIC):

   - Selección hacia adelante (*Forward*).
   - Eliminación hacia atrás (*Backward*).
   - Selección por pasos (*Stepwise* - Both).
   - *Discuta:* ¿Llegan los tres métodos al mismo modelo final?

3. **Mejores Subconjuntos (Best Subsets):** Utilice la función `regsubsets()` del paquete `leaps` para evaluar todas las combinaciones posibles de variables.

   - Identifique el mejor modelo según el R^2 ajustado.
   - Identifique el mejor modelo según el Criterio de Información Bayesiano (BIC).
   - *Conclusión Final:* Sintetice los resultados de todas las pruebas y declare cuál es, a su juicio, el modelo predictivo óptimo para estos datos.

5. Código de Apoyo en R (Tips para los Estudiantes)

```r
# Cargar librerías necesarias
library(tidyverse)
library(leaps) # Necesaria para la selección de mejores subconjuntos

# 1. Ejemplo de cómo calcular el promedio de peso por estudiante
# datos <- datos |>
#   rowwise() |>
#   mutate(peso_prom = mean(c(Medicion_1, Medicion_2, Medicion_3), na.rm = TRUE)) |>
#   ungroup()
```

```r
# 2. Ajuste del modelo con interacción
# modelo_interaccion <- lm(peso_prom ~ Estatura * Sexo, data = datos)
# summary(modelo_interaccion)

# 3. Gráfico sugerido
# ggplot(datos, aes(x = Estatura, y = peso_prom, color = Sexo)) +
#   geom_point() +
#   geom_smooth(method = "lm", se = FALSE) +
#   labs(title = "Relación Peso vs Estatura por Sexo",
#        x = "Estatura (m)", y = "Peso Promedio (kg)") +
#   theme_minimal()

# 4. Comparación de modelos con ANOVA
# modelo_reducido <- lm(peso_prom ~ Estatura + Sexo, data = datos)
# modelo_completo <- lm(peso_prom ~ Estatura + Sexo + Edad, data = datos)
# anova(modelo_reducido, modelo_completo)

# 5. Selección Stepwise (Ejemplo Backward)
# modelo_full <- lm(peso_prom ~ Estatura * Sexo * Edad, data = datos)
# modelo_back <- step(modelo_full, direction = "backward")

# 6. Selección por Mejores Subconjuntos
# subconjuntos <- regsubsets(peso_prom ~ Estatura * Sexo * Edad, data = datos, nvmax = 5)
# summary(subconjuntos)
# plot(subconjuntos, scale = "bic") # Gráfico útil para decidir con BIC
```