

Limpieza de datos

Mario Morales

Lectura y preparación de los datos

Objetivo general

Enfrentar al estudiante al “dato sucio” y real.

Objetivo específico

Realizar la preparación de los datos tomados en el laboratorio para que queden listos para la realización del informe que deberán presentar los estudiantes. La preparación incluye:

- Lectura
- Limpieza
- Imputación
- Anonimización

Lectura, Limpieza e Imputación en R

Lectura

Para esta tarea usaremos el sistema R base.

```
library(readxl) ①  
df <- read_excel("DatosLab1.xlsx") ②  
df <- as.data.frame(df) ③
```

- ① Librería para leer archivos de Excel
- ② Lectura
- ③ Convertimos a `data.frame` puro de R Base para evitar el formato tibble

Inspección visual de los datos

```
head(df)
```

	Marca temporal	Dirección de correo electrónico
1	2026-03-11 12:56:49	schavescontreras80@correo.unicordoba.edu.co
2	2026-03-11 13:38:07	josuedramos@correo.unicordoba.edu.co
3	2026-03-11 13:52:10	mhlopez@correo.unicordoba.edu.co
4	2026-03-11 14:31:58	acrivero@correo.unicordoba.edu.co
5	2026-03-11 14:46:28	lpatriciaramirez@correo.unicordoba.edu.co
6	2026-03-11 14:52:44	vgaleano@correo.unicordoba.edu.co

	Nombre Completo	Documento	Fecha de Nacimiento	Edad	Sexo
1	Sofia Chaves Contreras	1.00037298E9	2001-06-10	24.0	Femenino
2	Josué David Ramos Sánchez	1.13797762E9	2007-05-16	18.0	Masculino
3	Mauro López Martínez	1.062434362E9	2007-02-09	19.0	Masculino
4	Andres Camilo Rivero Pacheco	1.067864128E9	2006-09-22	19.0	Masculino
5	Laura Patricia Ramírez Polo	1.071.352.721	2007-12-01	18.0	Femenino
6	Verónica Galeano Martínez	1.062434986E9	2007-06-29	18.0	Femenino

	Teléfono / Contacto	Consentimiento informado diligenciado
1	3.106945186E9	Si
2	3.207847832E9	Si
3	3.206853212E9	Si
4	3.21358451E9	Si
5	3.002720373E9	Si
6	3.13786016E9	Si

	Cuestionario PAR-Q diligenciado	Apto para la evaluación / práctica
1	Si	Si
2	Si	Si
3	Si	Si
4	Si	Si
5	Si	Si
6	Si	Si

	Restricción o condición reportada por el participante
1	Si
2	Si
3	No
4	No
5	No
6	No

	Frecuencia cardíaca en reposo (lpm)	Presión arterial sistólica (mmHg)
1	85	122

2		75		125
3		72		113
4		88		108
5		74		110
6		78		105
Presión arterial diastólica (mmHg) Estatura Masa Corporal				
1		90	156.4 cm	60.3 kg
2		82	182.0	90.7
3		69	166.0	54.3
4		71	180.5	69.0
5		70	157.5	52.0
6		67	156.6	55.2
Perímetro de Cintura IMC Masa Grasa Masa Magra / Muscular Masa Ósea				
1	73.4 cm	24.7 kg/m ²	32.8 %	38.4 Kg 2.1 kg
2	89.4	27.4	25.2	22.9 3.4
3	70.5	19.8	15.9	43.3 2.3
4	73.0	21.2	17.8	53.9 2.9
5	67.8	21.0	30.6	34.2 1.9
6	70.0	22.5	27.6	38.0 2.0
Grasa Visceral Fuerza prensil mano derecha Fuerza prensil mano izquierda				
1	3.0		28.0	26.0
2	6.0		32.0	34.0
3	1.0		30.0	28.0
4	2.0		38.0	40.0
5	1.0		24.0	24.0
6	1.0		28.0	22.0

Inspección visual de los datos: Columnas 6 hasta el final

```
head(df[,6:ncol(df)])
```

	Edad	Sexo	Teléfono / Contacto	Consentimiento informado diligenciado
1	24.0	Femenino	3.106945186E9	Si
2	18.0	Masculino	3.207847832E9	Si
3	19.0	Masculino	3.206853212E9	Si
4	19.0	Masculino	3.21358451E9	Si
5	18.0	Femenino	3.002720373E9	Si
6	18.0	Femenino	3.13786016E9	Si
Cuestionario PAR-Q diligenciado Apto para la evaluación / práctica				
1			Si	Si

2	Si	Si
3	Si	Si
4	Si	Si
5	Si	Si
6	Si	Si
Restricción o condición reportada por el participante		
1	Si	
2	Si	
3	No	
4	No	
5	No	
6	No	
Frecuencia cardíaca en reposo (lpm) Presión arterial sistólica (mmHg)		
1	85	122
2	75	125
3	72	113
4	88	108
5	74	110
6	78	105
Presión arterial diastólica (mmHg) Estatura Masa Corporal		
1	90 156.4 cm	60.3 kg
2	82 182.0	90.7
3	69 166.0	54.3
4	71 180.5	69.0
5	70 157.5	52.0
6	67 156.6	55.2
Perímetro de Cintura IMC Masa Grasa Masa Magra / Muscular Masa Ósea		
1	73.4 cm 24.7 kg/m ²	32.8 % 38.4 Kg 2.1 kg
2	89.4 27.4	25.2 22.9 3.4
3	70.5 19.8	15.9 43.3 2.3
4	73.0 21.2	17.8 53.9 2.9
5	67.8 21.0	30.6 34.2 1.9
6	70.0 22.5	27.6 38.0 2.0
Grasa Visceral Fuerza prensil mano derecha Fuerza prensil mano izquierda		
1	3.0	28.0 26.0
2	6.0	32.0 34.0
3	1.0	30.0 28.0
4	2.0	38.0 40.0
5	1.0	24.0 24.0
6	1.0	28.0 22.0

Inspección visual de los datos str

```
str(df[,6:ncol(df)])
```

```
'data.frame': 37 obs. of 20 variables:
 $ Edad : chr "24.0" "18.0" "19.0" "19.0" .
 $ Sexo : chr "Femenino" "Masculino" "Masculino" .
 $ Teléfono / Contacto : chr "3.106945186E9" "3.207847832E9" .
 $ Consentimiento informado diligenciado : chr "Si" "Si" "Si" "Si" ...
 $ Cuestionario PAR-Q diligenciado : chr "Si" "Si" "Si" "Si" ...
 $ Apto para la evaluación / práctica : chr "Si" "Si" "Si" "Si" ...
 $ Restricción o condición reportada por el participante: chr "Si" "Si" "No" "No" ...
 $ Frecuencia cardíaca en reposo (lpm) : num 85 75 72 88 74 78 112 78 54 88
 $ Presión arterial sistólica (mmHg) : num 122 125 113 108 110 105 137 110 105 105
 $ Presión arterial diastólica (mmHg) : num 90 82 69 71 70 67 33 46 82 64
 $ Estatura : chr "156.4 cm" "182.0" "166.0" "166.0" .
 $ Masa Corporal : chr "60.3 kg" "90.7" "54.3" "69.0" .
 $ Perímetro de Cintura : chr "73.4 cm" "89.4" "70.5" "73.0" .
 $ IMC : chr "24.7 kg/m^2" "27.4" "19.8" "19.8" .
 $ Masa Grasa : chr "32.8 %" "25.2" "15.9" "17.8" .
 $ Masa Magra / Muscular : chr "38.4 Kg" "22.9" "43.3" "53.9" .
 $ Masa Ósea : chr "2.1 kg" "3.4" "2.3" "2.9" .
 $ Grasa Visceral : chr "3.0" "6.0" "1.0" "2.0" ...
 $ Fuerza prensil mano derecha : chr "28.0" "32.0" "30.0" "38.0" .
 $ Fuerza prensil mano izquierda : chr "26.0" "34.0" "28.0" "40.0" .
```

Renombrar columnas

En el Formato de registro de variables, hay nombres largos como **Frecuencia cardíaca en reposo**. En R base es una buena práctica:

- Evitar espacios: Usar guiones bajos (_).
- Evitar tildes y eñes: Para prevenir problemas de codificación (encoding).
- Minúsculas: R es sensible a mayúsculas (case-sensitive), y escribir todo en minúsculas evita errores comunes de digitación.

Recuperar los nombres actuales

```
colnames(df)
```

```
[1] "Marca temporal"
[2] "Dirección de correo electrónico"
[3] "Nombre Completo"
[4] "Documento"
[5] "Fecha de Nacimiento"
[6] "Edad"
[7] "Sexo"
[8] "Teléfono / Contacto"
[9] "Consentimiento informado diligenciado"
[10] "Cuestionario PAR-Q diligenciado"
[11] "Apto para la evaluación / práctica"
[12] "Restricción o condición reportada por el participante"
[13] "Frecuencia cardíaca en reposo (lpm)"
[14] "Presión arterial sistólica (mmHg)"
[15] "Presión arterial diastólica (mmHg)"
[16] "Estatura"
[17] "Masa Corporal"
[18] "Perímetro de Cintura"
[19] "IMC"
[20] "Masa Grasa"
[21] "Masa Magra / Muscular"
[22] "Masa Ósea"
[23] "Grasa Visceral"
[24] "Fuerza prensil mano derecha"
[25] "Fuerza prensil mano izquierda"
```

Asignar nuevos nombres

Creamos un vector con los nuevos nombres

```
nombres=c("marca_temp","email","nombre","documento","f_nac", "edad","sexo","tel", "consentim.
```

Asignar nuevos nombres

```
colnames(df)=nombres
```

Imprimir los nuevos nombres

```
colnames(df)
```

```
[1] "marca_temp"      "email"           "nombre"          "documento"
[5] "f_nac"           "edad"            "sexo"            "tel"
[9] "consentimiento" "par_q"           "apto"            "restriccion"
[13] "fcr"             "presion_sis"     "presion_dia"     "estatura"
[17] "masa_corporal"   "cintura"         "imc"             "masa_grasa"
[21] "masa_muscular"   "masa_osea"       "grasa_vis"       "fuerza_md"
[25] "fuerza_mi"
```

Tipos de datos en las columnas

Un vistazo a estatura

```
estat_sucio=df$estatura
estat_sucio
```

```
[1] "156.4 cm" "182.0"    "166.0"    "180.5"    "157.5"    "156.6"
[7] "172.3"    "164.5"    "181.0"    "168.6"    "177.0"    "163,2"
[13] "175,5 cm" "1.7"      "163.4"    "175.5"    "182.5"    "155.2"
[19] "174.2"    "1.7"      "156.5"    "165 cm"   "157.2 cm" "181.0"
[25] "189.5"    "1.57"     "167.5"    "158.4"    "165.5"    "171.5"
[31] "172.5"    "164.7"    "160.8"    "160.0"    "178.4"    "1.72"
[37] "163.9"
```

Limpieza de “Datos Contaminados” (Uso de Expresiones Regulares)

Para limpiar el “60.3 kg” usaremos `gsub` para eliminar texto y `as.numeric` para transformar.

```
# Limpieza de la columna Edad
# gsub("[^0-9.]", "", x) elimina todo lo que NO sea número o punto
df$edad <- gsub("[^0-9.]", "", df$edad)
df$edad <- as.numeric(df$edad)
# Aplicamos lo mismo a estatura y masa corporal
df$estatura <- as.numeric(gsub("[^0-9.]", "", df$estatura))
df$masa_corporal <- as.numeric(gsub("[^0-9.]", "", df$masa_corporal))
```

Continue usted

Haga lo mismo con las columnas que faltan

Warning: NAs introduced by coercion

Warning: NAs introduced by coercion

Warning: NAs introduced by coercion

Warning: NAs introduced by coercion

Warning: NAs introduced by coercion

```
'data.frame':  37 obs. of  14 variables:
 $ edad      : num  24 18 19 19 18 18 18 20 18 19 ...
 $ fcr       : num  85 75 72 88 74 78 112 78 54 85 ...
 $ presion_sis : num  122 125 113 108 110 105 137 118 124 135 ...
 $ presion_dia : num  90 82 69 71 70 67 33 46 82 64 ...
 $ estatura   : num  156 182 166 180 158 ...
 $ masa_corporal: num  60.3 90.7 54.3 69 52 55.2 67.3 51.5 66 70 ...
 $ cintura    : num  73.4 89.4 70.5 73 67.8 70 79 68 73.9 82 ...
 $ imc        : chr   "24.7 kg/m^2" "27.4" "19.8" "21.2" ...
 $ masa_grasa  : num  32.8 25.2 15.9 17.8 30.6 27.6 19.4 14.4 23.8 24.6 ...
 $ masa_muscular: num  38.4 22.9 43.3 53.9 34.2 38 51.5 41.8 47.7 50.2 ...
 $ masa_osea   : num  2.1 3.4 2.3 2.9 1.9 2 2.7 2.3 2.6 2.7 ...
 $ grasa_vis   : num  3 6 1 2 1 1 2.5 1 1 5 ...
 $ fuerza_md   : num  28 32 30 38 24 28 40 36 42 42 ...
 $ fuerza_mi   : num  26 34 28 40 24 22 36 34 42 48 ...
```