

# Limpieza de datos

Mario Morales

## Lectura y preparación de los datos

Versión para los estudiantes.

### Objetivo general

Enfrentar al estudiante al “dato sucio” y real.

### Objetivo específico

Realizar la preparación de los datos tomados en el laboratorio para que queden listos para la realización del informe que deberán presentar los estudiantes. La preparación incluye:

- Lectura
- Limpieza
- Imputación
- Anonimización

## Lectura, Limpieza e Imputación en R

### Lectura

Para esta tarea usaremos el sistema R base.

```
library(readxl)
df <- read_excel("DatosLab1.xlsx")
df <- as.data.frame(df)
```

①

②

③

① Librería para leer archivos de Excel

- ② Lectura
- ③ Convertimos a `data.frame` puro de R Base para evitar el formato tibble

## Inspección visual de los datos

```
head(df)
```

|   | Marca temporal      | Dirección de correo electrónico             |
|---|---------------------|---------------------------------------------|
| 1 | 2026-03-11 12:56:49 | schavescontreras80@correo.unicordoba.edu.co |
| 2 | 2026-03-11 13:38:07 | josuedramos@correo.unicordoba.edu.co        |
| 3 | 2026-03-11 13:52:10 | mhlopez@correo.unicordoba.edu.co            |
| 4 | 2026-03-11 14:31:58 | acrivero@correo.unicordoba.edu.co           |
| 5 | 2026-03-11 14:46:28 | lpatriciaramirez@correo.unicordoba.edu.co   |
| 6 | 2026-03-11 14:52:44 | vgaleano@correo.unicordoba.edu.co           |

  

|   | Nombre Completo              | Documento     | Fecha de Nacimiento | Edad | Sexo      |
|---|------------------------------|---------------|---------------------|------|-----------|
| 1 | Sofia Chaves Contreras       | 1.00037298E9  | 2001-06-10          | 24.0 | Femenino  |
| 2 | Josué David Ramos Sánchez    | 1.13797762E9  | 2007-05-16          | 18.0 | Masculino |
| 3 | Mauro López Martínez         | 1.062434362E9 | 2007-02-09          | 19.0 | Masculino |
| 4 | Andres Camilo Rivero Pacheco | 1.067864128E9 | 2006-09-22          | 19.0 | Masculino |
| 5 | Laura Patricia Ramírez Polo  | 1.071.352.721 | 2007-12-01          | 18.0 | Femenino  |
| 6 | Verónica Galeano Martínez    | 1.062434986E9 | 2007-06-29          | 18.0 | Femenino  |

  

|   | Teléfono / Contacto | Consentimiento informado diligenciado |
|---|---------------------|---------------------------------------|
| 1 | 3.106945186E9       | Si                                    |
| 2 | 3.207847832E9       | Si                                    |
| 3 | 3.206853212E9       | Si                                    |
| 4 | 3.21358451E9        | Si                                    |
| 5 | 3.002720373E9       | Si                                    |
| 6 | 3.13786016E9        | Si                                    |

  

|   | Cuestionario PAR-Q diligenciado | Apto para la evaluación / práctica |
|---|---------------------------------|------------------------------------|
| 1 | Si                              | Si                                 |
| 2 | Si                              | Si                                 |
| 3 | Si                              | Si                                 |
| 4 | Si                              | Si                                 |
| 5 | Si                              | Si                                 |
| 6 | Si                              | Si                                 |

  

|   | Restricción o condición reportada por el participante |
|---|-------------------------------------------------------|
| 1 | Si                                                    |
| 2 | Si                                                    |
| 3 | No                                                    |
| 4 | No                                                    |

|   |                                     |                                                           |
|---|-------------------------------------|-----------------------------------------------------------|
| 5 |                                     | No                                                        |
| 6 |                                     | No                                                        |
|   | Frecuencia cardíaca en reposo (lpm) | Presión arterial sistólica (mmHg)                         |
| 1 | 85                                  | 122                                                       |
| 2 | 75                                  | 125                                                       |
| 3 | 72                                  | 113                                                       |
| 4 | 88                                  | 108                                                       |
| 5 | 74                                  | 110                                                       |
| 6 | 78                                  | 105                                                       |
|   | Presión arterial diastólica (mmHg)  | Estatura Masa Corporal                                    |
| 1 | 90                                  | 156.4 cm 60.3 kg                                          |
| 2 | 82                                  | 182.0 90.7                                                |
| 3 | 69                                  | 166.0 54.3                                                |
| 4 | 71                                  | 180.5 69.0                                                |
| 5 | 70                                  | 157.5 52.0                                                |
| 6 | 67                                  | 156.6 55.2                                                |
|   | Perímetro de Cintura                | IMC Masa Grasa Masa Magra / Muscular Masa Ósea            |
| 1 | 73.4 cm                             | 24.7 kg/m <sup>2</sup> 32.8 % 38.4 Kg 2.1 kg              |
| 2 | 89.4                                | 27.4 25.2 22.9 3.4                                        |
| 3 | 70.5                                | 19.8 15.9 43.3 2.3                                        |
| 4 | 73.0                                | 21.2 17.8 53.9 2.9                                        |
| 5 | 67.8                                | 21.0 30.6 34.2 1.9                                        |
| 6 | 70.0                                | 22.5 27.6 38.0 2.0                                        |
|   | Grasa Visceral                      | Fuerza prensil mano derecha Fuerza prensil mano izquierda |
| 1 | 3.0                                 | 28.0 26.0                                                 |
| 2 | 6.0                                 | 32.0 34.0                                                 |
| 3 | 1.0                                 | 30.0 28.0                                                 |
| 4 | 2.0                                 | 38.0 40.0                                                 |
| 5 | 1.0                                 | 24.0 24.0                                                 |
| 6 | 1.0                                 | 28.0 22.0                                                 |

### Inspección visual de los datos: Columnas 6 hasta el final

```
head(df[,6:ncol(df)])
```

|   |      |           |                     |                                       |
|---|------|-----------|---------------------|---------------------------------------|
|   | Edad | Sexo      | Teléfono / Contacto | Consentimiento informado diligenciado |
| 1 | 24.0 | Femenino  | 3.106945186E9       | Si                                    |
| 2 | 18.0 | Masculino | 3.207847832E9       | Si                                    |
| 3 | 19.0 | Masculino | 3.206853212E9       | Si                                    |
| 4 | 19.0 | Masculino | 3.21358451E9        | Si                                    |

|                                                                          |      |          |                        |          |                |
|--------------------------------------------------------------------------|------|----------|------------------------|----------|----------------|
| 5                                                                        | 18.0 | Femenino | 3.002720373E9          |          | Si             |
| 6                                                                        | 18.0 | Femenino | 3.13786016E9           |          | Si             |
| Cuestionario PAR-Q diligenciado Apto para la evaluación / práctica       |      |          |                        |          |                |
| 1                                                                        |      |          | Si                     |          | Si             |
| 2                                                                        |      |          | Si                     |          | Si             |
| 3                                                                        |      |          | Si                     |          | Si             |
| 4                                                                        |      |          | Si                     |          | Si             |
| 5                                                                        |      |          | Si                     |          | Si             |
| 6                                                                        |      |          | Si                     |          | Si             |
| Restricción o condición reportada por el participante                    |      |          |                        |          |                |
| 1                                                                        |      |          |                        | Si       |                |
| 2                                                                        |      |          |                        | Si       |                |
| 3                                                                        |      |          |                        | No       |                |
| 4                                                                        |      |          |                        | No       |                |
| 5                                                                        |      |          |                        | No       |                |
| 6                                                                        |      |          |                        | No       |                |
| Frecuencia cardíaca en reposo (lpm) Presión arterial sistólica (mmHg)    |      |          |                        |          |                |
| 1                                                                        |      |          | 85                     |          | 122            |
| 2                                                                        |      |          | 75                     |          | 125            |
| 3                                                                        |      |          | 72                     |          | 113            |
| 4                                                                        |      |          | 88                     |          | 108            |
| 5                                                                        |      |          | 74                     |          | 110            |
| 6                                                                        |      |          | 78                     |          | 105            |
| Presión arterial diastólica (mmHg) Estatura Masa Corporal                |      |          |                        |          |                |
| 1                                                                        |      |          | 90                     | 156.4 cm | 60.3 kg        |
| 2                                                                        |      |          | 82                     | 182.0    | 90.7           |
| 3                                                                        |      |          | 69                     | 166.0    | 54.3           |
| 4                                                                        |      |          | 71                     | 180.5    | 69.0           |
| 5                                                                        |      |          | 70                     | 157.5    | 52.0           |
| 6                                                                        |      |          | 67                     | 156.6    | 55.2           |
| Perímetro de Cintura IMC Masa Grasa Masa Magra / Muscular Masa Ósea      |      |          |                        |          |                |
| 1                                                                        |      | 73.4 cm  | 24.7 kg/m <sup>2</sup> | 32.8 %   | 38.4 Kg 2.1 kg |
| 2                                                                        |      | 89.4     | 27.4                   | 25.2     | 22.9 3.4       |
| 3                                                                        |      | 70.5     | 19.8                   | 15.9     | 43.3 2.3       |
| 4                                                                        |      | 73.0     | 21.2                   | 17.8     | 53.9 2.9       |
| 5                                                                        |      | 67.8     | 21.0                   | 30.6     | 34.2 1.9       |
| 6                                                                        |      | 70.0     | 22.5                   | 27.6     | 38.0 2.0       |
| Grasa Visceral Fuerza prensil mano derecha Fuerza prensil mano izquierda |      |          |                        |          |                |
| 1                                                                        |      | 3.0      |                        | 28.0     | 26.0           |
| 2                                                                        |      | 6.0      |                        | 32.0     | 34.0           |
| 3                                                                        |      | 1.0      |                        | 30.0     | 28.0           |
| 4                                                                        |      | 2.0      |                        | 38.0     | 40.0           |
| 5                                                                        |      | 1.0      |                        | 24.0     | 24.0           |

## Inspección visual de los datos `str`

```
str(df[,6:ncol(df)])
```

```
'data.frame':  37 obs. of  20 variables:
 $ Edad                : chr  "24.0" "18.0" "19.0" "19.0" .
 $ Sexo                : chr  "Femenino" "Masculino" "Masculino"
 $ Teléfono / Contacto : chr  "3.106945186E9" "3.207847832E9"
 $ Consentimiento informado diligenciado : chr  "Si" "Si" "Si" "Si" ...
 $ Cuestionario PAR-Q diligenciado       : chr  "Si" "Si" "Si" "Si" ...
 $ Apto para la evaluación / práctica   : chr  "Si" "Si" "Si" "Si" ...
 $ Restricción o condición reportada por el participante: chr  "Si" "Si" "No" "No" ...
 $ Frecuencia cardíaca en reposo (lpm)   : num  85 75 72 88 74 78 112 78 54 88
 $ Presión arterial sistólica (mmHg)     : num  122 125 113 108 110 105 137 110
 $ Presión arterial diastólica (mmHg)    : num  90 82 69 71 70 67 33 46 82 64
 $ Estatura                    : chr  "156.4 cm" "182.0" "166.0" "182.0"
 $ Masa Corporal              : chr  "60.3 kg" "90.7" "54.3" "69.0"
 $ Perímetro de Cintura       : chr  "73.4 cm" "89.4" "70.5" "73.0"
 $ IMC                       : chr  "24.7 kg/m^2" "27.4" "19.8" "27.4"
 $ Masa Grasa                 : chr  "32.8 %" "25.2" "15.9" "17.8"
 $ Masa Magra / Muscular     : chr  "38.4 Kg" "22.9" "43.3" "53.9"
 $ Masa Ósea                 : chr  "2.1 kg" "3.4" "2.3" "2.9" ..
 $ Grasa Visceral            : chr  "3.0" "6.0" "1.0" "2.0" ...
 $ Fuerza prensil mano derecha : chr  "28.0" "32.0" "30.0" "38.0" .
 $ Fuerza prensil mano izquierda : chr  "26.0" "34.0" "28.0" "40.0" .
```

## Renombrar columnas

En el Formato de registro de variables, hay nombres largos como `Frecuencia cardíaca en reposo`. En R base es una buena práctica:

- Evitar espacios: Usar guiones bajos (`_`).
- Evitar tildes y eñes: Para prevenir problemas de codificación (encoding).
- Minúsculas: R es sensible a mayúsculas (case-sensitive), y escribir todo en minúsculas evita errores comunes de digitación.

## Recuperar los nombres actuales

```
colnames(df)
```

```
[1] "Marca temporal"
[2] "Dirección de correo electrónico"
[3] "Nombre Completo"
[4] "Documento"
[5] "Fecha de Nacimiento"
[6] "Edad"
[7] "Sexo"
[8] "Teléfono / Contacto"
[9] "Consentimiento informado diligenciado"
[10] "Cuestionario PAR-Q diligenciado"
[11] "Apto para la evaluación / práctica"
[12] "Restricción o condición reportada por el participante"
[13] "Frecuencia cardíaca en reposo (lpm)"
[14] "Presión arterial sistólica (mmHg)"
[15] "Presión arterial diastólica (mmHg)"
[16] "Estatura"
[17] "Masa Corporal"
[18] "Perímetro de Cintura"
[19] "IMC"
[20] "Masa Grasa"
[21] "Masa Magra / Muscular"
[22] "Masa Ósea"
[23] "Grasa Visceral"
[24] "Fuerza prensil mano derecha"
[25] "Fuerza prensil mano izquierda"
```

## Asignar nuevos nombres

Creamos un vector con los nuevos nombres

```
nombres=c("marca_temp","email","nombre","documento","f_nac", "edad","sexo","tel", "consentim
```

## Asignar nuevos nombres

```
colnames(df)=nombres
```

## Imprimir los nuevos nombres

```
colnames(df)
```

```
[1] "marca_temp"      "email"           "nombre"          "documento"
[5] "f_nac"           "edad"            "sexo"            "tel"
[9] "consentimiento"  "par_q"           "apto"            "restriccion"
[13] "fcr"             "presion_sis"     "presion_dia"     "estatura"
[17] "masa_corporal"   "cintura"         "imc"             "masa_grasa"
[21] "masa_muscular"   "masa_osea"       "grasa_vis"       "fuerza_md"
[25] "fuerza_mi"
```

## Tipos de datos en las columnas

### Un vistazo a estatura

```
estat_sucio=df$estatura
estat_sucio
```

```
[1] "156.4 cm" "182.0"    "166.0"    "180.5"    "157.5"    "156.6"
[7] "172.3"    "164.5"    "181.0"    "168.6"    "177.0"    "163,2"
[13] "175,5 cm" "1.7"      "163.4"    "175.5"    "182.5"    "155.2"
[19] "174.2"    "1.7"      "156.5"    "165 cm"   "157.2 cm" "181.0"
[25] "189.5"    "1.57"     "167.5"    "158.4"    "165.5"    "171.5"
[31] "172.5"    "164.7"    "160.8"    "160.0"    "178.4"    "1.72"
[37] "163.9"
```

## Limpieza de “Datos Contaminados” (Uso de Expresiones Regulares)

Para limpiar el “60.3 kg” usaremos `gsub` para eliminar texto y `as.numeric` para transformar.

```
# Limpieza de la columna Edad
# gsub("[^0-9.]", "", x) elimina todo lo que NO sea número o punto
df$edad <- gsub("[^0-9.]", "", df$edad)
df$edad <- as.numeric(df$edad)
# Aplicamos lo mismo a estatura y masa corporal
df$estatura <- as.numeric(gsub("[^0-9.]", "", df$estatura))
df$masa_corporal <- as.numeric(gsub("[^0-9.]", "", df$masa_corporal))
```

## Continue usted

Haga lo mismo con las columnas que faltan

```
Warning: NAs introduced by coercion
Warning: NAs introduced by coercion
Warning: NAs introduced by coercion
Warning: NAs introduced by coercion
Warning: NAs introduced by coercion
```

```
'data.frame': 37 obs. of 14 variables:
 $ edad      : num 24 18 19 19 18 18 18 20 18 19 ...
 $ fcr       : num 85 75 72 88 74 78 112 78 54 85 ...
 $ presion_sis : num 122 125 113 108 110 105 137 118 124 135 ...
 $ presion_dia : num 90 82 69 71 70 67 33 46 82 64 ...
 $ estatura   : num 156 182 166 180 158 ...
 $ masa_corporal: num 60.3 90.7 54.3 69 52 55.2 67.3 51.5 66 70 ...
 $ cintura    : num 73.4 89.4 70.5 73 67.8 70 79 68 73.9 82 ...
 $ imc        : chr "24.7 kg/m^2" "27.4" "19.8" "21.2" ...
 $ masa_grasa  : num 32.8 25.2 15.9 17.8 30.6 27.6 19.4 14.4 23.8 24.6 ...
 $ masa_muscular: num 38.4 22.9 43.3 53.9 34.2 38 51.5 41.8 47.7 50.2 ...
 $ masa_osea   : num 2.1 3.4 2.3 2.9 1.9 2 2.7 2.3 2.6 2.7 ...
 $ grasa_vis   : num 3 6 1 2 1 1 2.5 1 1 5 ...
 $ fuerza_md   : num 28 32 30 38 24 28 40 36 42 42 ...
 $ fuerza_mi   : num 26 34 28 40 24 22 36 34 42 48 ...
```