

Guia para presentar el informe del laboratorio

1.

Mario Morales

Guía para el Informe de Laboratorio: “Análisis Biométrico y Funcional”

Este informe debe ser un documento técnico de alto nivel. Aquí tiene la estructura sugerida:

Introducción y Justificación Fisiológica

Los estudiantes deben investigar y profundizar en la naturaleza de las variables medidas, por ejemplo:

- **Frecuencia Cardíaca en Reposo (FCR):** Explicar que una FCR elevada puede estar asociada a un menor volumen sistólico o menor eficiencia cardíaca. ¿Qué implicaciones tiene esto en el riesgo cardiovascular?
- **Bioimpedancia Eléctrica:** ¿Cómo mide la báscula la grasa visceral y el agua corporal?. Deben explicar el principio de resistencia de los tejidos al paso de una corriente eléctrica leve.
- **Fuerza Prensil:** Investigar por qué la fuerza de agarre se considera hoy un “biomarcador de envejecimiento” y salud general.

Metodología

- Descripción de los instrumentos (Tensiómetro, Dinamómetro, Báscula de Bioimpedancia).
- Descripción del proceso de limpieza de datos realizado en R.

Resultados y Análisis Estadístico

- **Análisis Descriptivo:** Tablas de frecuencia, medidas de tendencia central y dispersión para IMC, Masa Magra y Masa Grasa.
- **Visualización de Datos:** * Histogramas de la distribución de la Presión Arterial.
- Diagramas de dispersión (Scatter plots) para ver la relación entre Masa Muscular y Fuerza Prensil.
- **Análisis por Grupo:** Comparar los promedios de Composición Corporal entre hombres y mujeres usando diagramas de caja (boxplots).
- Comparar los resultados del grupo con los valores de referencia internacionales (OMS).

Tareas Complementarias de Análisis

Para profundizar en la relación entre las variables biométricas, cada grupo deberá:

1. **Análisis de Correlación:** Calcular la matriz de correlación para las variables numéricas limpias. ¿Qué variables están más asociadas con la Grasa Visceral?
2. **Modelado Alternativo:** Ajustar un modelo de regresión para predecir la **Fuerza Prensil** usando como predictores la **Masa Magra** y la **Estatura**. Reportar el modelo y su capacidad explicativa (R^2).
3. **Visualización Avanzada:** Crear un diagrama de dispersión de la relación más fuerte encontrada, etiquetando los puntos que el modelo de regresión identificó como “atípicos” (outliers).

Refinamiento de Datos y Predicción de Valores Faltantes

En clase usamos medidas de tendencia central (la mediana) para llenar los vacíos de información (como los registros de grasa visceral o IMC faltantes en menores de 18 años).

Ahora se debe aplicar un Modelo de Imputación por Regresión. A continuación se dan las instrucciones para hacerlo.

Construcción del Modelo Predictivo:

Se deberá ajustar un modelo de regresión lineal múltiple utilizando el subconjunto de datos que esté completo.

- Variable Respuesta (Y): La variable que presenta el dato faltante (ej. `imc` o `grasa_viscerar`).
- Variables Predictoras (X_n): Variables con alta correlación biológica como estatura, `masa_corporal`, `cintura` y `fuerza_prensil`.
- Evaluación de la Bondad de Ajuste: Antes de imputar, el grupo debe reportar el Coeficiente de Determinación (R^2). Esto les permitirá discutir qué tan confiable es el modelo para predecir los datos de sus compañeros.

Ejecución de la Imputación: Utilizando la función `predict()` en R, deberán estimar los valores específicos para aquellos estudiantes que no contaban con la medida original.

Análisis Crítico: En la sección de Discusión, deberán comparar si los promedios del grupo cambian significativamente al usar este método predictivo en comparación con la mediana simple.

Sugerencia:

- En R Base: Pueden usar la función `lm()` y luego asignar los valores faltantes usando indexación:

```
df$imcn[is.na(df$imcn)] <- predict(modelo, newdata = ...)
```

- En Tidyverse: Pueden usar el paquete `recipes` o simplemente un `mutate()` combinado con `if_else(is.na(.))`

Discusión y Conclusiones

Escriba aquí una discusión sobre los resultados y conclusiones.

Anexo: Guía de Implementación para Imputación por Regresión

Para estimar los valores faltantes (registros con NA), se sugieren tres pasos:

- Filtrar los datos completos para entrenar el modelo
- Ajustar la regresión
- Predecir los vacíos.

Opción A: El Mundo de R Base (Enfoque Procedural)

Este método es ideal para entender la manipulación directa de vectores e índices.

1. Crear un subset con los datos completos para el modelo

```
datos_completos <- df[!is.na(df$imcn), ]
```

2. Ajustar el modelo de regresión lineal múltiple

```
# Ejemplo: IMC en función de estatura, masa corporal y cintura
modelo_base <- lm(imcn ~ estatura + masa_corporal + cintura, data = datos_completos)
```

3. Ver el resumen del modelo (R-cuadrado y significancia)

```
summary(modelo_base)
```

4. Identificar las filas que tienen NA en imcn

```
filas_faltantes <- is.na(df$imcn)
```

5. Imputar los valores usando la función predict

```
# Solo se reemplazan los NAs con la estimación del modelo
df$imcn[filas_faltantes] <- predict(modelo_base, newdata = df[filas_faltantes, ])
```

Opción B: El Mundo de Tidyverse (Enfoque Funcional)

Este método destaca por su legibilidad y el uso de “tuberías” (`%>%` o `|>`) para el flujo de datos.

Fragmento de código

1. Ajustar el modelo usando el dataframe filtrado internamente

```
modelo_tidy <- lm(imcn ~ estatura + masa_corporal + cintura,
                 data = df %>% filter(!is.na(imcn)))
```

2. Imputar usando mutate e if_else

```
# Si es NA, usa la predicción; si no, deja el valor original
df <- df %>%
  mutate(imcn = if_else(
    is.na(imcn),
    predict(modelo_tidy, newdata = .),
    imcn
  ))
```

3. Verificación rápida con `skimr`

```
# El conteo de 'n_missing' para imcn ahora debe ser 0
library(skimr)
df %>% skim(imcn)
```