# Guia para presentar el informe del laboratorio 1.

Mario Morales

## Guía para el Informe de Laboratorio: "Análisis Biométrico y Funcional"

Este informe debe ser un documento técnico de alto nivel. Aquí tiene la estructura sugerida:

### Introducción y Justificación Fisiológica

Los estudiantes deben investigar y profundizar en la naturaleza de las variables medidas, por ejemplo:

- **Frecuencia Cardíaca en Reposo (FCR):** Explicar que una FCR elevada puede estar asociada a un menor volumen sistólico o menor eficiencia cardíaca. ¿Qué implicaciones tiene esto en el riesgo cardiovascular?
- **Bioimpedancia Eléctrica:** ¿Cómo mide la báscula la grasa visceral y el agua corporal?. Deben explicar el principio de resistencia de los tejidos al paso de una corriente eléctrica leve.
- **Fuerza Prensil:** Investigar por qué la fuerza de agarre se considera hoy un "biomarcador de envejecimiento" y salud general.

### Metodología

- Descripción de los instrumentos (Tensiómetro, Dinamómetro, Báscula de Bioimpedancia).
- Descripción del proceso de limpieza e integración de datos realizado en R, detallando cómo se unieron las bases de datos de los semestres 2026-1 y 2026-2 y la creación de la variable indicadora de "Semestre".

### Resultados y Análisis Estadístico

- **Análisis Descriptivo:** Tablas de frecuencia, medidas de tendencia central y dispersión para IMC, Masa Magra y Masa Grasa.
- **Visualización de Datos:** * Histogramas de la distribución de la Presión Arterial, superponiendo o separando gráficamente las distribuciones de los semestres 2026-1 y 2026-2.
- Diagramas de dispersión (Scatter plots) para ver la relación entre Masa Muscular y Fuerza Prensil, diferenciando los puntos con colores o formas según el semestre al que pertenece cada estudiante.
- **Análisis por Grupo:** Comparar los promedios de Composición Corporal entre hombres y mujeres usando diagramas de caja (boxplots), y emplear facetas (paneles separados) para contrastar si estas diferencias por género se mantienen constantes entre las cohortes 2026-1 y 2026-2.
- Comparar los resultados de los dos grupos, 2026-1 y 2026-2, con los valores de referencia internacionales (OMS).

### Tareas Complementarias de Análisis

Para profundizar en la relación entre las variables biométricas, cada grupo deberá:

1. **Análisis de Correlación:** Calcular la matriz de correlación para las variables numéricas limpias. ¿Qué variables están más asociadas con la Grasa Visceral?
2. **Modelado Alternativo:** Ajustar un modelo de regresión para predecir la **Fuerza Prensil** usando como predictores la **Masa Magra**, la **Estatura** y el **Semestre** como variable categórica. Reportar el modelo, su capacidad explicativa ($R^2$) y discutir si pertenecer a un semestre u otro tiene un efecto significativo en la fuerza.
3. **Visualización Avanzada:** Crear un diagrama de dispersión de la relación más fuerte encontrada, etiquetando los puntos que el modelo de regresión identificó como "atípicos" (outliers).

## Refinamiento de Datos y Predicción de Valores Faltantes

En clase usamos medidas de tendencia central (la mediana) para llenar los vacíos de información (como los registros de grasa visceral o IMC faltantes en menores de 18 años).

Ahora se debe aplicar un Modelo de Imputación por Regresión. A continuación se dan las instrucciones para hacerlo.

**Construcción del Modelo Predictivo:**

Se deberá ajustar un modelo de regresión lineal múltiple utilizando el subconjunto de datos que esté completo.

- Variable Respuesta ($Y$): La variable que presenta el dato faltante (ej. `imc` o `grasa_visceral`).
- Variables Predictoras ($X_n$): Variables con alta correlación biológica como `estatura`, `masa_corporal`, `cintura`, `fuerza_prensil` y la variable categórica del semestre.
- Evaluación de la Bondad de Ajuste: Antes de imputar, el grupo debe reportar el Coeficiente de Determinación ($R^2$). Esto les permitirá discutir qué tan confiable es el modelo para predecir los datos de sus compañeros.

Ejecución de la Imputación: Utilizando la función `predict()` en R, deberán estimar los valores específicos para aquellos estudiantes que no contaban con la medida original.

Análisis Crítico: En la sección de Discusión, deberán comparar si los promedios del grupo cambian significativamente al usar este método predictivo en comparación con la mediana simple.

Sugerencia:

- En R Base: Pueden usar la función `lm()` y luego asignar los valores faltantes usando indexación:

```
df$imcn[is.na(df$imcn)] <- predict(modelo, newdata = ...)
```

- En Tidyverse: Pueden usar el paquete `recipes` o simplemente un `mutate()` combinado con `if_else(is.na(.))`

### Discusión y Conclusiones

Escriba aquí una discusión sobre los resultados y conclusiones.

## Anexo: Guía de Implementación para Imputación por Regresión

Para estimar los valores faltantes (registros con NA), se sugieren tres pasos:

- Filtrar los datos completos para entrenar el modelo
- Ajustar la regresión
- Predecir los vacíos.

### Opción A: El Mundo de R Base (Enfoque Procedural)

Este método es ideal para entender la manipulación directa de vectores e índices.

1. Crear un subset con los datos completos para el modelo

```
datos_completos <- df[!is.na(df$imcn), ]
```

2. Ajustar el modelo de regresión lineal múltiple

```
# Ejemplo: IMC en función de estatura, masa corporal, cintura y semestre (periodo)
modelo_base <- lm(imcn ~ estatura + masa_corporal + cintura + periodo, data = datos_completos
```

3. Ver el resumen del modelo (R-cuadrado y significancia)

```
summary(modelo_base)
```

4. Identificar las filas que tienen `NA` en `imcn`

```
filas_faltantes <- is.na(df$imcn)
```

5. Imputar los valores usando la función `predict`

```
# Solo se reemplazan los NAs con la estimación del modelo
df$imcn[filas_faltantes] <- predict(modelo_base, newdata = df[filas_faltantes, ])
```

### Opción B: El Mundo de Tidyverse (Enfoque Funcional)

Este método destaca por su legibilidad y el uso de "tuberías" (%>% o |>) para el flujo de datos.

### Fragmento de código

1. Ajustar el modelo usando el `dataframe` filtrado internamente

```
modelo_tidy <- lm(imcn ~ estatura + masa_corporal + cintura + periodo,
                  data = df %>% filter(!is.na(imcn)))
```

2. Imputar usando `mutate` e `if_else`

```r
# Si es NA, usa la predicción; si no, deja el valor original
df <- df %>%
  mutate(imcn = if_else(
    is.na(imcn),
    predict(modelo_tidy, newdata = .),
    imcn
  ))
```

3. Verificación rápida con `skimr`

```r
# El conteo de 'n_missing' para imcn ahora debe ser 0
library(skimr)
df %>% skim(imcn)
```

## Anexo 2: Visualización comparativa con ggplot2

Para visualizar las diferencias o similitudes entre las cohortes de los dos semestres, `ggplot2` es la herramienta ideal.

El secreto radica en la función `aes()` (estéticas). Si le indicamos a R que el `color` o la `shape` (forma) dependen de la variable categórica `periodo`, el paquete automáticamente agrupará los datos, pintará los puntos con colores distintos y generará la leyenda correspondiente.

Aquí tienen un ejemplo base de cómo graficar la relación entre la Masa Muscular y la Fuerza Prensil, separando por semestre:

```r
# Asegúrese de tener cargada la librería
library(ggplot2)

# Construcción del gráfico de dispersión (Scatter plot)
ggplot(data = df, aes(x = masa_muscular, y = fuerza_prensil, color = periodo)) +
  geom_point(size = 3, alpha = 0.7) +    # alpha le da una ligera transparencia a los puntos
  geom_smooth(method = "lm", se = FALSE) + # Agrega las líneas de tendencia de regresión lin
  labs(
    title = "Relación entre Masa Muscular y Fuerza Prensil",
    subtitle = "Comparación de tendencias entre las cohortes 2026-1 y 2026-2",
    x = "Masa Muscular (kg)",
    y = "Fuerza Prensil (kg)",
    color = "Semestre Académico"
  ) +
  theme_minimal() # Un tema limpio y profesional
```